

데이터마이닝 중간 보고서

- 학번·이름: 2024720459 황동욱
- 과목: 성균관대학원 2-1 데이터마이닝
- 주제: 공공 RFP × 산업뉴스 × 규제 데이터 기반 산업별 Pain Point 분석 및 컨설팅 프로세스(ISP·PI·POC·BPR)별 제안 전략 자동화 데이터 허브 구축
- 작성일: 2026-04-23
- GitHub: <https://github.com/hwangdongwuk/DataMining>

① 프로젝트 개요

1.1 연구 질문

1. 나라장터 RFP 본문·산업 뉴스·규제 공시를 통합 분석하면 **산업별 반복 Pain Point를 정량화**할 수 있는가?
2. 도출된 Pain Point가 **ISP·PI·POC·BPR·PMO 중 어느 컨설팅 유형 수요와 연결**되는지 자동 분류할 수 있는가?
3. 이를 통해 **제안 전략(Win Strategy) 핵심 포인트를 자동 추출**하여 제안서 작성에 활용할 수 있는가?

1.2 선정 이유

- 보험·금융 IT 기획/PM 실무에서 제안서 작성 시 Pain Point 파악과 Win Strategy 수립에 **수일이 소요**되는 비효율을 데이터 파이프라인으로 자동화.
- 수업의 "데이터 허브" 개념에 부합하며, 최종 Streamlit 허브는 제안팀 실무 도구로 즉시 전환 가능.

1.3 W02 피드백 반영

W06 강의 피드백("좋은 연구 질문 자가 진단")을 적용하여 질문을 구체화: - **[구체적 대상]** 나라장터 **용역 공고** (3년치, 2023~2025) - **[측정 가능한 변수]** 공고 건수, 예산(presmptPrce), 키워드 빈도, 컨설팅 유형 태그 - **[시간/공간 범위]** 2023-01-01 ~ 2025-12-31 (36개월) - **[방향성]** 산업별 Pain Point 상위 키워드 비교, 컨설팅 유형별 수요 추이

W06 "다중 데이터 소스 결합" 피드백에 따라 **Key-based Join(bidNtceNo)** 으로 메타 + 첨부 본문 + (향후) 금감원 RSS · 네이버 뉴스 결합 설계.

② 데이터 수집 결과

2.1 데이터 소스

#	소스	유형	접근	상태
1	나라장터 입찰공고 OpenAPI (용역)	REST API (JSON)	data.go.kr 서비스키	✅ 수집 완료
2	나라장터 첨부 PDF/HWP	파일 다운로드	API 응답 내 URL	✅ 샘플 완료

#	소스	유형	접근	상태
3	네이버 뉴스 검색 API	REST API (JSON)	developers.naver.com	✅ 수집 완료
4	금융위원회(FSC) RSS	RSS 2.0	fsc.go.kr (보도·공지·행정예고)	✅ 수집 완료

2.2 수집 규모

- 나라장터 공고 메타 (용역): 420,104 건 · 수요기관 16,551 곳
- 기간: 2023-01-01 ~ 2025-11-25 (27개월, 학습 일정상 조기 중단)
- 월별 분할 JSONL: 27 개 (data/raw/narajangteo/*.jsonl)
- 나라장터 첨부 파일(샘플): 197 건 → PDF 본문 173건 성공 추출
- 네이버 뉴스: 13,765 건 (15 키워드 × 10페이지 · 중복 제거 후)
- 금융위원회 RSS: 30 건 (보도 10 · 공지 10 · 행정예고 10)

2.3 수집 코드 핵심

```
# src/collect_narajangteo_api.py
BASE_URL = "https://apis.data.go.kr/12300000/ad/BidPublicInfoService"
# 월별 분할 + 페이지네이션(999rows) + 지수 백오프 재시도
for s, e in month_ranges("20230101", "20251231"):
    for page in range(1, total_pages + 1):
        payload = fetch_page(key, endpoint, s, e, page, 999)
        append_jsonl(payload.items())
        time.sleep(0.1)
```

2.4 주요 필드 (66개 중 핵심 17)

필드	의미
bidNtceNo / bidNtceOrd	공고번호 / 차수 (PK)
bidNtceNm	공고명
bidNtceDt	공고일시
ntceInsttNm / dminsttNm	공고기관 / 수요기관
presmptPrce	추정가격(원)
bidBeginDt / bidClseDt / opengDt	입찰 시작/마감/개찰
ntceSpecDocUrl1~10	첨부파일 URL (최대 10개)

③ 데이터 전처리

3.1 파이프라인

1. JSONL 통합 로드 → pd.DataFrame (66컬럼, 월별 36파일 concat)
2. 중복 제거: (bidNtceNo, bidNtceOrd) 기준

3. 타입 변환: `bidNtceDt` → `datetime`, 가격 필드 → `numeric`
4. 결측치 처리:
5. `presmptPrce` 결측은 NaN 유지 (미확정 공고 특성 반영, 대체 X)
6. 첨부 URL 빈 문자열 → 누락으로 처리
7. 파생 변수:
8. `year`, `year_month`
9. `industry`: 공고명 키워드 매칭 (보험 / 금융 / IT / 기타)
10. `consulting_type`: ISP / PI / POC / BPR / PMO / 구축 / 기타
11. 첨부 본문 추출: `pdfplumber` (PDF), `hwp5txt` (HWP)
12. 형태소 분석: `kiwipiepy` 로 명사 추출 (길이 ≥ 2)

Python 3.14 환경에서 `konlpy` / `gensim` 빌드 실패 → 순수 Python `kiwipiepy` + `sklearn.decomposition.LatentDirichletAllocation` 으로 대체.

3.2 Before / After

항목	Before (raw JSONL)	After (rfp_meta.csv)
스키마	66 컬럼 혼재	핵심 17컬럼 + 파생 5컬럼
날짜	문자열	<code>datetime64[ns]</code>
중복	재공고·차수 혼재	(<code>bidNtceNo</code> , <code>bidNtceOrd</code>) 단위 정리
분류	없음	<code>industry × consulting_type</code> 태그

④ 탐색적 데이터 분석 (EDA)

(`notebooks/01_eda.ipynb` 와 `reports/figures/` 에서 자동 생성)

4.1 기초 통계

- 연도별 공고 건수: 2023 / 2024 / 2025 비교 막대그래프 → `figures/count_by_year.png`
- 월별 추이: 계절성(연말 몰림 등) 확인 → `figures/count_by_month.png`
- 예산 분포: `presmptPrce` 히스토그램 (로그 스케일) + 중앙값/IQR

4.2 카테고리 분포

- 산업별 비율: 보험 / 금융 / IT / 기타 파이 차트
- 컨설팅 유형 교차표: `industry × consulting_type` 히트맵

4.3 상관 / 공통 출현

- 공고명 상위 TF-IDF 키워드 워드클라우드 (전체 / 산업별 3종)
- 기관별 발주 랭킹 Top 20

⑤ 중간 인사이트 / 가설

(데이터 확보 후 1차 검증 결과 갱신)


예상 가설: - H1: 2023→2025 동안 "AI / 데이터 / 클라우드" 키워드 공고 **비중이 증가** 한다. - H2: 금융·보험 업종에서 "ISP → 구축" 순으로 **발주가 시간차를 두고 이어지는 패턴** 이 존재한다. - H3: 공고명에 "혁신 / 재설계 / 고도화" 키워드가 포함된 공고가 그렇지 않은 공고보다 **평균 예산이 유의하게 크다**.

⑥ 향후 계획

주차	작업	산출물
W09	첨부 PDF/HWP 전수 다운·본문 추출, 뉴스·규제 RSS 결합	rfp_text.csv, news.csv
W10	TF-IDF + LDA (sklearn) 토픽 모델링 8~12 토픽	topics.json
W11	규제 → 발주 시차 분석, Win Strategy 포인트 룰 정의	시차 분석 표
W12	Streamlit 대시보드 고도화 (워드클라우드 · 타임라인 · Win Strategy 추출기)	app_streamlit.py
W13	EC2 배포 + CloudFront/Route53 검토	공개 URL
W14	최종 발표 및 라이브 시연	발표자료, demo URL

⑦ AWS 인프라 구성

7.1 아키텍처 (W07 "데이터 허브 = AWS" 5단계 매핑)



7.2 현재 구성 상태

서비스	상태	용도	비고
AWS 계정	✅ 257925264162	—	프리티어
IAM 사용자 hwangdonguk	✅ 활성	CLI/API 접근	Access Key 발급 완료
EC2 t3.micro datamining_demo	✅ 실행 중	분석·Streamlit 서빙	ap-southeast-2a, Amazon Linux 2023
Security Group sg-0b7c854caa4d4e287	✅ SSH 허용	22번 포트, 내 IP(1.220.29.220/32) 한정	—

서비스	상태	용도	비고
S3 버킷 <code>datamining-257925264162-raw</code>	✅ 생성	raw/processed/final 계층	퍼블릭 차단, 버저닝 On
EventBridge + Lambda	📅 W11 예정	일일 자동 수집	cron(0 0 ? * MON-FRI *)
SageMaker / Colab GPU	📅 W12 예정	토픽 모델링	Studio 프리티어

7.3 비용 관리

- AWS Budgets **\$5/월 알람 필수 설정** (W07 권고)
- 사용 종료 시 인스턴스 **Terminate** (Stop만 하면 EBS 과금 지속)
- S3 버킷 **Private 고정** (Presigned URL로 임시 공유)
- NAT Gateway 사용 안 함 (\$30+/월 과금 회피)

부록 A. 리포지토리 구조

```

DataMining/
├── .env                # API 키 (gitignore)
├── .gitignore
├── README.md
├── requirements.txt
├── data/
│   ├── raw/
│   │   ├── narajangteo/    # *.jsonl (월별 36파일)
│   │   └── rfp_files/      # {bidNtceNo}/*.pdf,hwp
│   └── processed/
│       ├── rfp_meta.csv
│       ├── rfp_text.csv
│       └── rfp_tokens.csv
├── notebooks/
│   └── 01_eda.ipynb
├── reports/
│   ├── midterm.md         # 본 문서
│   ├── midterm.pdf        # 제출본
│   └── figures/*.png
├── src/
│   ├── collect_narajangteo_api.py
│   ├── download_attachments.py
│   ├── preprocess_rfp.py
│   ├── eda.py
│   └── app_streamlit.py
└── scripts/
    └── aws_bootstrap.sh    # S3 버킷 생성·업로드 자동화

```

부록 B. 실행 방법

```
# 1) 환경
python3 -m venv .venv && source .venv/bin/activate
pip install -r requirements.txt

# 2) 3년치 수집 (월별 분할, 999rows)
python src/collect_narajangteo_api.py \
    --start 20230101 --end 20251231 \
    --kind 용역 --split monthly --rows 999

# 3) 첨부 샘플 다운로드 (500건)
python src/download_attachments.py --sample 500

# 4) 전처리 & 태깅
python src/preprocess_rfp.py

# 5) AWS S3 업로드
bash scripts/aws_bootstrap.sh

# 6) 대시보드 실행
streamlit run src/app_streamlit.py
```