

공공 RFP × 산업 Pain Point 데이터 허브

데이터마이닝 중간 보고

빅데이터학과 황동욱 (2024720459)

문제 정의

실무 Pain Point

- GA · 보험 · 금융 IT 기획/PM 현장에서 제안서 1건 작성에 **3~5일** 소요
- 담당자마다 매번 **고객 Pain Point 수동 분석** → 재사용성 낮음
- **Win Strategy 가설 수립**이 경험 의존적 → 신입 입문 장벽 높음

본 프로젝트의 질문 (수식화)

산업별 Pain Point(i) = f (RFP 키워드 빈도, 뉴스 언급 빈도, 규제 공시 시차)

컨설팅 유형(j) = $\operatorname{argmax} P(j \mid \text{Pain Point 패턴, 공고명 토큰})$

Win Strategy 포인트 = $\operatorname{top-k}(\text{TF-IDF} \times \text{예산 가중} \times \text{시차 상관})$

기대 효과

- 제안팀 실무 도구로 즉시 전환 가능한 **Streamlit 대시보드**
- 반복 업무 시간 **수일 → 수시간** 단축 가설

연구 질문

1. 나라장터 RFP · 산업 뉴스 · 규제 공시를 통합 분석하면 **산업별 반복 Pain Point** 를 정량화할 수 있는가?
2. 도출된 Pain Point가 **ISP · PI · POC · BPR · PMO** 중 어느 컨설팅 유형 수요와 연결되는가?
3. **Win Strategy 핵심 포인트** 를 자동 추출해 제안서 작성에 활용할 수 있는가?

W06 피드백 반영 공식

[구체적 대상] + [측정 가능한 변수] + [시간·공간 범위] + [방향성]
↳ 나라장터 용역 ↳ 공고 건수·예산·키워드 ↳ 2023-01 ~ 2025-11 ↳ 증가·차이·상관

5단계 파이프라인

5-단계 데이터 파이프라인




나라장터 API · 첨부 PDF/HWP · 네이버 뉴스 · 금융위 RSS → Pain Point 인사이트

단계별 산출물

- ① 수집 → JSONL 27개 월별 분할 파일
- ② 저장 → S3 총 25객체 · **2.1 GB**
- ③ 처리 → CSV 3종 (rfp_meta , rfp_text , news_meta)
- ④ 분석 → TF-IDF · LDA · 시차 분석 (W10~W12 예정)
- ⑤ 시각화 → Streamlit 4탭 (개요·추이·키워드·검색)

Key-based Join 설계

Key-based Join 설계: bidNtceNo 기반 통합



통합 키 전략

- **기본 키:** bidNtceNo (광고 단위, N:N join 대비 중복 제거 우선 적용)
- **보조 키:** 날짜(year_month), 키워드, 기관명
- **결합 패턴:** 나라장터 메타 $\leftarrow$ 첨부 본문 $\leftarrow$ 뉴스(키워드 매칭) $\leftarrow$ 규제(시계열)

수집 KPI

수집 KPI 요약



기간: 2023-01-01 ~ 2025-11-25 (27개월) · S3 총 25 객체 · 2.1 GB

실측 수치 요약

- 나라장터 메타: 420,104건 · 수요기관 16,551곳
- 첨부 파일 샘플: 197 → PDF 본문 173 (추출 성공률 87.8%)
- 뉴스: 15,000 수집 → 중복 제거 후 13,765건 (정제율 91.8%)
- 규제 공시 (FSC RSS): 30건 (보도·공지·행정예고)

AWS 데이터허브 아키텍처

AWS 데이터허브 아키텍처 (W07 매핑)



현재 구현 상태: EC2 running · S3 버킷 생성 · Access Key 발급 · SSH/8501 개방


현재 운영 리소스

- **계정** 257925264162 · 리전 ap-southeast-2 (시드니)
- **EC2** t3.micro `datamining_demo` (running · 13.239.237.95)
- **S3** `datamining-257925264162-raw` (버저닝 · 퍼블릭 차단)
- **IAM** 사용자 `hwangdonguk` (Access Key · S3FullAccess)

- **Security Group** `sg-0b7c854caa4d4e287` (SSH 22 · Streamlit 8501)

EDA ① 산업별 분포


산업별 분포



해석

- 기타 88.5% · IT 9.0% · 보험 2.0% · 금융 0.4%
- "기타" 비중이 큼 → 도메인 키워드 사전 확충 필요 (W09 과제)
- 금융/보험 업종은 소수이지만 평균 예산이 IT 대비 ~2배


EDA ② 연도별 추이



해석

- 2023/2024/2025 연도별 발주 건수 고르게 분포
- 2025년은 11월 25일까지 수집 기준
- 연말 분기(11~12월) 피크 경향 관찰 → 계절성 존재


EDA ③ 월별 시계열



관찰

- **분기 말** 집중 발주 패턴 (3·6·9·12월)
- 공공 예산 회계연도 사이클 반영
- 시차 분석 시 **규제 공시** → **발주 lag** 검증 가능


EDA ④ 산업 × 컨설팅 유형 교차



수치 해석

- 구축 23,236 · PMO 4,510 · POC 1,515 · ISP 448 · PI 478 · BPR 21
- IT 업종 = 구축 중심
- PMO 수요는 서울시·국토교통부가 견인
- ISP/PI 비중은 전체의 0.25% — 사전 전략형 발주 자체가 희소


EDA ⑤ 수요기관 Top 20



수치

- 서울특별시 **3,097건** (1위)
- 한국어촌어항공단 1,697 · 국토교통부 1,657
- **상위 20 기관이 전체의 약 6%** 차지
- 장기적으로 **"단골 발주처"** 중심 타깃 설계 가능


EDA ⑥ 공고명 키워드 Top 30



해석

- 상위 3: 운영(28,039) · 실시설계용역(14,483) · 구축(11,618)
- 관리형(유지관리·유지보수) vs 구축형 키워드 1:1 비중
- 높은 빈도 키워드 = Pain Point 후보군


EDA ⑦ 본문 키워드 (PDF 첨부 173건)



관찰

- 계약·입찰·이행·수급인·감리 등 **계약 관리 용어** 우세
- 향후 Requirement 섹션만 추출 시 → **기술 Pain Point 키워드**로 치환 가능
- TF-IDF + sklearn LDA 8~12 토픽 (W10 계획)

예산 분포



수치 해석

평균 약 40.7억원 >> 중앙값 약 7,157만원
↑
소수 초대형 공고가 평균을 왜곡

- 분포 **극단적 우편향** (log-skew)
- 회귀 분석 시 **`log1p(presmptPrce)`** 변환 권장
- IQR 기반 이상치 제거 후 모델링 (W10)

중간 인사이트

발견된 패턴


- 공고 88% 이상 "기타" 산업 태그 → 도메인 키워드 사전 확충 필요
- 컨설팅 유형 중 구축(23K) 압도적 · ISP/PI 등 사전형 희소
- 상위 20 수요기관이 전체 6% 점유
- 예산 분포가 log-space 에서 정규 근접 → 회귀 전처리에 log1p
- 뉴스 "ISP 발주" 키워드에서 실제 ISP 용역 공고 직접 언급 확인

가설

- H1 2023→2025 기간 "AI/데이터/클라우드" 공고 비중 증가
- H2 금융·보험 업종은 "ISP → 구축" 순으로 시차 있는 연쇄 발주
- H3 "혁신·재설계·고도화" 키워드 포함 공고의 평균 예산이 유의하게 크다
- H4 규제 공시(FSC RSS) 발생 후 N개월 내 관련 발주 증가

향후 계획 (Gantt 요약)

주차별 로드맵



AWS 인프라 자동화

- EventBridge + Lambda 로 일일 자동 수집
- SageMaker Studio 에서 GPU 기반 토픽 모델링 실험
- CloudWatch 알람 · Budgets \$5/월 유지

감사합니다

리소스

- **GitHub**: <https://github.com/hwangdongwuk/DataMining>
- **Streamlit** (로컬/EC2 포트 8501): 실시간 분석 대시보드
- **S3**: `s3://datamining-257925264162-raw`

문의

황동욱 (2024720459) · 빅데이터학과