

공공 RFP Pain Point 허브

데이터마이닝 중간 보고

빅데이터학과 황동욱 (2024720459)

프로젝트 개요

연구주제

- 공공 RFP × 산업뉴스 × 규제 데이터 기반 **산업별 Pain Point 분석** 및 컨설팅 프로세스(ISP·PI·POC·BPR)별 **제안 전략 자동화 데이터 허브 구축**

연구질문

- 나라장터 RFP · 산업 뉴스 · 규제 공시를 통합 분석하면 **산업별 반복 Pain Point** 를 정량화할 수 있는가?
- 도출된 Pain Point가 **ISP · PI · POC · BPR · PMO** 중 어느 컨설팅 유형 수요와 연결되는지 자동 분류할 수 있는가?
- **Win Strategy 핵심 포인트** 를 자동 추출해 제안서 작성에 활용할 수 있는가?

선정이유

- 보험·금융 IT 기획/PM 실무 경험 기반 관심
- 제안서 작성 시 Pain Point 파악·Win Strategy 수립에 수일 소요되는 비효율
- 데이터 파이프라인으로 자동화 시 제안팀 실무 도구로 즉시 전환 가능

데이터 수집

수집방법

1. data.go.kr 에서 나라장터 OpenAPI 활용 신청 → 서비스키 발급
2. developers.naver.com 에서 검색 API Client ID/Secret 발급
3. Python `requests` + `feedparser` 로 API 호출 → JSONL 저장
4. AWS S3 버킷(`datamining-257925264162-raw`) 에 원본 일괄 저장

수집 카테고리 (Key-based Join, 기본키 = `bidNtceNo`)

- [나라장터 입찰공고](#) (용역) — 메타 66필드
- [첨부 PDF/HWP](#) — 공고별 최대 10개 URL
- [네이버 뉴스](#) — 15개 키워드 (ISP·BPR·PMO·PoC·핀테크·FDS 등)
- [금융위원회 RSS](#) — 보도·공지·행정예고

수집 규모

- 나라장터: **420,104건** · 수요기관 **16,551곳** · 2023-01 ~ 2025-11 (27개월)
- 나라장터 첨부 샘플: **197건** → PDF 본문 추출 **173건**
- 네이버 뉴스: **13,765건** (중복 제거 후)
- 금융위원회 RSS: **30건**

제약

- 나라장터 API 응답 속도 한계 → 월별 분할·지수 백오프 재시도로 대응
- 네이버 검색 API: 키워드당 `start` 최대 1000
- Python 3.14 환경에서 `konlpy` / `gensim` 빌드 실패 → `kiwipiepy` + `sklearn.LDA` 로 대체

데이터 전처리

1) 결측치 처리

- 추정가격(`presmptPrce`) 결측 → NaN 유지 (미확정 공고 특성 반영, 대체 X)
- 첨부 URL 빈 문자열 → 누락 처리
- 뉴스 본문 HTML 태그 → 정규식으로 모두 제거

2) 데이터 타입 변환

- `bidNtceDt`, `pubDate` → datetime
- `presmptPrce`, `bssamt` → numeric (쉼표 제거 후 변환)

3) 데이터 정제

- 중복 제거 (`bidNtceNo` + `bidNtceOrd` 기준)
- 파생 변수 생성 (`year`, `year_month`)
- 산업 태그 (보험 / 금융 / IT / 기타)
- 컨설팅 유형 태그 (ISP / PI / POC / BPR / PMO / 구축 / 기타)
- 첨부 PDF → `pdfplumber`, HWP → `hwp5txt` 로 본문 추출
- 형태소 분석 `kiwipiepy` 명사 추출 (길이 ≥ 2)

4) 전처리 전후 비교

- 원본 458,421건 → 중복 제거 후 **420,104건**
- 스키마 66컬럼 혼재 → 핵심 17 + 파생 5 → **22컬럼**
- 분류 없음 → `industry × consulting_type` 태그 완료

탐색적 데이터 분석 (EDA)

데이터 개요

- 총 공고 수: **420,104건** · 수요기관 **16,551곳**
- 기간: 2023-01-01 ~ 2025-11-25 (27개월)
- 추정가격 평균 40.7억 vs 중앙값 7,157만 → **극단치 분포**
- 상위 수요기관: 서울특별시(3,097) > 한국어촌어항공단 > 국토교통부

분포 분석

- 공고 건수 연도별 고르게 분포, 월별로 연말·분기말 피크
- 추정가격 → 로그 스케일 시 정규 분포 근접
- 산업별 비율: **기타 88.5%** · IT 9.0% · 보험 2.0% · 금융 0.4% → "기타" 비중이 큼 (산업 태그 룰 보강 필요)

산업 × 컨설팅 유형 교차

- 구축 23,236 · PMO 4,510 · POC 1,515 · ISP 448 · PI 478 · BPR 21
- IT 업종은 **구축 중심**, PMO 수요는 서울시·국토교통부가 견인

탐색적 데이터 분석 (EDA)

공고명 주요 키워드 Top 10

- 운영 (28,039) · 실시설계용역 (14,483) · 구축 (11,618)
- 유지관리 (9,548) · 개발 (9,598) · 유지보수 (7,691) → 제안서 자동화에서 높은 빈도 키워드 = Pain Point 후보군

첨부 본문(PDF) 주요 키워드

- 계약·입찰·이행·수급인·감리 등 계약 관리 용어 우세
- 향후 Requirement 섹션만 추출하면 기술 Pain Point 키워드로 치환 가능

뉴스 × 공고 시계열 관계 (탐색)

- 뉴스 발행량 증가 키워드(ISP·BPR·PMO) ↔ 나라장터 발주 피크 시점 비교 예정

중간 인사이트

발견된 패턴

- 공고 **88% 이상이 "기타" 산업 태그** → 도메인 키워드 사전 확충 필요
- 컨설팅 유형 태그 중 **구축(23K)** 이 압도적, ISP/PI 등 사전형은 소수
- 수요기관 상위 20개가 전체 공고의 약 **6%** 점유
- 추정가격 분포가 로그 스케일에서 정규 근접 → 회귀 전처리 시 `log1p` 적용 타당
- 네이버 뉴스 키워드 중 **"ISP 발주"** 에서 실제 ISP 용역 공고 직접 언급 확인

가설

- **H1.** 2023→2025 기간 동안 "AI/데이터/클라우드" 키워드 공고 비중이 증가한다
- **H2.** 금융·보험 업종은 "ISP → 구축" 순으로 시간차를 두고 발주가 이어진다
- **H3.** 공고명에 "혁신·재설계·고도화" 키워드 포함 시 평균 예산이 유의하게 크다
- **H4.** 규제 공시(FSC RSS) 발생 후 N개월 내 관련 발주 건수가 증가한다

향후 계획

데이터 추가 수집

- 3년치 나머지 9개월 + 2026년 1분기 확장
- 금감원(FSS) RSS 추가, 공공데이터포털 "규제 정보" 보조 소스

모델 고도화

- TF-IDF + sklearn LDA 8~12 토픽 모델링
- 규제 → 발주 시차 분석 (Granger 검정 또는 교차상관)
- Win Strategy 룰 기반 추출기 (키워드 패턴 + 예산 구간)

시각화

- **Streamlit** 대시보드: 개요 · 월별 추이 · 키워드 · 공고 검색 (구현 완료)
- EC2 `datamining_demo` 에 배포 → 외부 공개 URL

AWS 인프라 운영

- EventBridge + Lambda 로 **일일 자동 수집** 파이프라인 구축
- SageMaker Studio 에서 GPU 기반 토픽 모델링 실험

감사합니다

GitHub: <https://github.com/hwangdongwuk/DataMining>