

공공 RFP × 산업 Pain Point 데이터 허브

나라장터 IT 발주 분석 · 2023-2025

데이터마이닝 기말 발표 · **황동욱** (2024720459)

성균관대학교 정보통신대학원 · 2026 Spring

 33,860건 ·  3,383 기관 ·  35개월 ·  AWS 라이브 배포

1. 연구 질문 & 발표 범위

중간 발표의 3대 질문

1. 산업별 반복 **Pain Point**를 정량화할 수 있는가?
2. Pain Point가 **컨설팅 유형**(ISP·PI·POC·구축) 수요와 연결되는가?
3. **Win Strategy** 핵심 포인트를 자동 추출할 수 있는가?

“검토의견 4차(P0): "산업 '기타' 88.5% — 분류 자체가 작동하지 않음”

- **기말** = ①·② 검증 + 분류 신뢰성 확보, ③ Win Strategy는 **실무 서비스로 구현**(p.15)

2. 중간 → 기말: 무엇이 달라졌나

중간 (현황 기술)

- 산업 '기타' 88.5% — 분류 미작동
- 가설 H1~H4 **제시만**, 검정 0건
- AI 비중 = 키워드 단순 매칭
- 분포·Top 등 describe 중심

기말 (검증·교정)

- 전처리 고도화 → 기타 **0%**
- H1·H3 가설검정 + 카이제곱
- AI 정의 **엄격 재교정** (과대 → 실측)
- 제안서 자동생성 **서비스 구상** (샘플)


“중간은 결과를 제시했고, 기말은 그 결과가 **맞는지·왜 그런지**를 검증했다”

3. 받은 피드백에 어떻게 답했나

출처	핵심 지적	본 발표의 답
교수 P0	산업 '기타' 88.5%	전처리 고도화 → 0% (p.6-7)
교수 Q3	H3를 t-test로 검증?	$p < 10^{-20}$ 지지 (p.8)
동료 다수	"기타 많아 교차 안 됨"	산업×컨설팅 카이제곱 유의 (p.11)
동료	우편향 심해 왜곡	평균·중앙 병기 + $\log_{10} p$ (p.14)
자체 점검	AI 비중 과대분류	21.7% → 9.0% 교정 (p.12)

※ 미해결: 첨부 PDF 전수추출·FSC 규제시차(표본 부족)는 한계로 명시(p.17)

4. 데이터 파이프라인



단계	스택
수집	나라장터 OpenAPI · 월별 분할 · 지수 백오프
저장	AWS S3 (datamining-...-raw)
전처리	Python · 키워드 색인(단어경계) · 기관 매핑 · 중복 제거
분석·서비스	scipy 검정 · Streamlit · Claude API

5. 전처리 고도화 — 정제 퍼널

전체 용역 공고	458,421
① IT 색인 (개발 다의어 제외)	53,909
② 영문토큰 단어경계	53,229
③ IT 비연관 도메인 제외	52,992
④ 논리적 중복 제거	33,860
+ ⑤ 산업 = 수요기관 기반 10범주 → 기타 0건 ⑥ 사업유형 16범주 → 기타 7.5%	

“분류축을 '공고명 키워드' → '수요기관 성격'으로 교체해 '기타'를 구조적으로 해소

6. 핵심 버그 — 영문 토큰 부분일치

AI · SW 키워드가 **영어 단어 내부**에 박혀 오색인:

m AI ntenance	F AI r	MRI Br AI n	LG AI mers	pa SSW ord
---------------------	--------------	-------------------	------------------	------------------

- 산업 '기타' 258건 중 **102건이 이 오탐** (MRI 판독·해커톤·박람회...)
- **해결**: 영문 토큰 → 단어경계(\b) 매칭 / 한글 키워드 → 부분일치 유지

“데이터 양은 많은데 결론이 약해지는” 오염을 근본 차단

7. 데이터 규모

33,860

정제 공고

3,383


수요기관

35

개월 연속

10·16

산업·유형 범주



8. 가설 검정 — 무엇을, 어떻게 확인했나

① AI 발주가 해마다 늘었나?

네 — 2년 새 약 2배 ↑

검증법 · 연도별 추세 비교 (6% → 13%)

② '고도화' 사업은 예산이 더 큰가?

네 — 평균 1.3배 더 큼

검증법 · 두 집단 평균 차이 (t-검정)

③ 산업마다 원하는 사업유형이 다른가?


네 — 뚜렷하게 다름

검증법 · 교차분석 (카이제곱 검정)

세 가설 모두 통계적으로 유의 = "우연으로 보기 어렵다" (t-검정·카이제곱으로 확인)

“중간발표 때 '계획'만 세운 가설을, 기말은 표준 통계기법으로 검증 완료”

9. 어느 산업이 IT를 발주하나 (전체)



전체 33,860건 기준 · 수요기관 성격 기반 10범주

“ 행정·공공(41.5%) + 교육·연구(18.7%) 가 공공 IT 발주의 60% — 발주량은 공공·교육이 주도 ”

10. Q①의 답 — 그중 AI는 어느 산업이 발주하나



엄격 정의 기준 · 사업유형별: 연구개발 36.4% · POC/실증 33.8% · 컨설팅 17.3%

“발주 ****'량'****은 행정·공공이 1위였지만, AI ****'비중'****은 정보·통신·교육연구가 주도 — 발주량 1위 행정·공공은 AI 6.9%로 하위 (양 ↔ AI 성숙도는 별개)”

11. Q②의 답 — 산업 × 컨설팅 유형 연결

산업 \ 유형	유지보수	구축	고도화	컨설팅
행정·공공	6,360	2,043	1,266	598
교육·연구	1,906	1,643	811	371
농림·수산·환경	1,121	486	513	168
국토·교통·건설	806	518	398	203

- 행정·공공 = 유지보수 압도 / 교육·연구 = 구축 비중↑
- 카이제곱 $\chi^2=2,824, p\approx 0 \rightarrow$ 산업과 유형은 통계적으로 유의하게 연관

“동료 지적("기타 많아 교차 안 됨")을 기타 0% + 검정으로 해소”

12. AI 순수성 — 정의를 교정하다 (자체 검증)

기존 분류는 데이터 · 클라우드 만으로 ai-pure 판정 → 58.6%가 비(非)AI 혼입

 뉴스 (담론) — 엄격 정의

29.8%

 RFP (실제 발주) — 엄격 정의

9.0%

💡 격차는 느슨(3.0배)→엄격(3.3배) 정의를 바꿔도 유지 = 강건한 결론 —
"AI 담론 ↔ 조달 현실"의 정량적 격차 (AI 분류: 자체 키워드 기준 / 민감도 분석)

13. IT 사업유형 — 16범주

유형	비중	유형	비중
유지보수/운영	37.6%	감리	4.5%
구축/개발	17.7%	ISP/계획	1.8%
고도화/개선	11.9%	연구개발	1.8%
컨설팅/분석	5.8%	임차/구독	1.4%
보안	5.5%	기타	7.5%

“공공 IT 지출의 절반 이상이 유지보수·운영·고도화 — 신규 구축은 18%에 불과

”

14. AI 예산의 역설

9,000만

ai-pure 중앙 예산

1.27억

non-ai 중앙 예산


$p < 10^{-11}$

Welch t = -6.91

“ AI 광고는 비중도 작고(9%) 건당 예산도 더 작다 — 아직 소규모 PoC·실증 단계 ”

담론은 AI를 미래로 말하지만, 실제 조달은 '운영·유지보수'에 예산이 몰림

15. 실무 서비스 구상 — 제안서 자동생성 (Q③ 확장)



- 적합 공고 탐지 → 회사 인적자산 기반 담당자 매칭 → 과거 제안서 목차로 어필 포인트
- Claude가 목차·핵심 메시지·차별화 전략이 담긴 가안 제안서 초안 생성
- 제안서 1건 작성 수일 → 수분 단축 (중간발표 기대효과의 확장 방향)

※ 담당자 매칭은 회사 인적자산 DB 기반 — 본 발표는 대략적 구성·샘플 화면 수준, 실구현은 향후

16. AWS 인프라 & 대시보드



- Streamlit 탭: 개요 · 월별 · 키워드(색인기준 공개) · **AI 순수성(엄격)** · 공고검색 · **제안서 생성**
- 영구 실행(systemd) + 공개 터널 → 모바일 접속 가능

🌐 <https://now-metallic-bringing-title.trycloudflare.com>

17. 결론 · 한계 · 향후

결론

- 전처리 고도화로 '기타' 88.5%→0%, H1·H3 가설검정 지지, 산업×유형 연관 확인
- AI는 **담론(30%) ↔ 발주(9%) 3.3배 격차** + 건당 예산도 작음 (정의 교정 후 강건)

한계 (솔직히)

- 산업축 = 수요기관 기반(공고명 기반 아님) · 첨부 PDF 173건 샘플 · FSC RSS 30건은 시차분석 표본 부족

향후

- PDF 본문 전수추출 + LDA · 규제→발주 Granger · 제안서 생성 정확도 평가셋 구축

18. 예상 질문 (Q&A)

“ Q. '기타 0%'는 분류를 잘한 건가, 축을 바꾼 건가?

→ 후자. 공고명 키워드로는 한계 → 수요기관 성격으로 재정의. 한계도 명시.

“ Q. AI 9%는 너무 낮지 않나?

→ 엄격 정의(핵심 AI 키워드만). 느슨하면 21.7%이나 답론 격차는 두 정의 모두 3배대로 강건.

“ Q. 예산 t-test가 인과인가?

→ 아니오. 연관(association). 공고기관·연도 통제된 회귀는 향후 과제.

감사합니다

GitHub github.com/hwangdongwuk/DataMining

대시보드 [trycloudflare](#) 공개 URL (라이브)

핵심 기타 0% · H1·H3 검정 · AI 격차 3.3배 · 제안서 자동생성

황동욱 · 데이터마이닝 2026