

공공 RFP × 산업 Pain Point 데이터 허브

나라장터 IT 발주 분석 · 2023-2025

데이터마이닝 중간과제 · **황동욱**

성균관대학교 정보통신대학원 · 2026 Spring

 33,860건 ·  수요기관 3,383곳 ·  35개월 ·  AWS 배포

1. 연구 질문 & 배경

- **연구 질문**: 공공부문은 어느 산업이, 어떤 유형의 IT 사업을, AI는 얼마나 발주하는가?
- **데이터 소스 (4종 결합)**: 나라장터 OpenAPI · 네이버 뉴스 · FSC RSS · 첨부 RFP
- **중간 검토의견서 4차 핵심 지적 (P0)**

“산업 분류 '기타' 88.5% — 분류 자체가 작동하지 않음”

- 본 발표 = 이 피드백을 전처리 고도화로 해결한 과정과 결과

2. 데이터 파이프라인

수집 → **정제(핵심)** → 분석 → 시각화(대시보드) → AWS 배포

단계	도구
수집	나라장터 OpenAPI (<code>getBidPblancListInfoServc</code>), 월별 분할·백오프
저장	AWS S3 (<code>datamining-...-raw</code>)
전처리	Python · 키워드 색인 · 기관 매핑 · 중복 제거
분석	산업·유형·AI 분류, EDA
시각화	Streamlit (EC2, systemd 영구 실행)

3. 전처리 고도화 — 6단계 (핵심 기여)

#	처리	효과
1	업무구분 IT 색인 (용역, 공사·외자 제외)	458K → 53K
2	단독 "개발" 다의어 제외 (IT 맥락만)	기타 88.5%→30.8%
3	영문토큰 단어경계 매칭 (AI/SW/IT)	air·fair·brain 오탐 제거
4	IT 비연관 도메인 제외 (행사·의료·건축)	비IT 배제
5	산업 = 수요기관 기반 10범주	기타 0건
6	논리적 중복 제거 (제목+기관+추정가)	48.7K → 33.9K


4. 핵심 버그 — 영문 토큰 부분일치

- AI 키워드가 **영어 단어 내부**에 박혀 오색인
 - m**a**intenance · F**ai**r · MRI Br**ai**n · LG **Ai**mers · ch**ai**n
 - **SW** → pa**ss**word · Gene**s**Well
- 산업 기타 258건 중 **102건이 이 오탐**
- **해결**: 영문 토큰을 단어경계(**\b**) 매칭으로 → 한글 키워드는 부분일치 유지


→ "데이터 양은 많은데 결론이 약해지는" 오염을 근본 차단

5. 데이터 규모

- **공고 33,860건** (중복 제거 후) · 수요기관 **3,383곳**
- 기간 **2023-01 ~ 2025-11 (35개월 연속)**
- 추정가격: 평균 **5.85억** · 중앙 **1.22억** (우편향, sentinel 정제)



6. 산업별 분포 (수요기관 기반 10범주)



- 행정·공공 41% · 교육·연구 19% · 농림수산환경 9% ...

7. IT 사업유형 (16범주)

유형	비중	유형	비중
유지보수/운영	37.6%	감리	4.5%
구축/개발	17.7%	ISP/계획	1.8%
고도화/개선	11.9%	연구개발	1.8%
컨설팅/분석	5.8%	임차/구독	1.4%
보안	5.5%	기타	7.5%

→ 공공 IT 지출의 **절반 이상이 유지보수·운영·고도화** (신규 구축은 18%)


8. AI 순수성 분석 (KAIB2026 기준)

- **방법론 차용**: ETRI KAIB2026 (국가 AI 재정계획) ai-pure / non-ai 키워드
- 발주(RFP) ai-pure **21.7%** vs 뉴스(담론) ai-pure **66.1%**

소스	ai-pure	non-ai
뉴스 (담론)	66.1%	33.9%
RFP (실제 발주)	21.7%	78.3%

“**핵심 인사이트**: 미디어는 AI 중심, 실제 공공 조달은 일반 정보화·SI 대다수 — “AI 관심 ↔ 조달 현실”의 정량적 격차

9. 수요기관 Top



10. AWS 인프라 & 대시보드

- **EC2** (t3.micro, ap-southeast-2) + **S3** + **IAM**
- Streamlit 5탭: 개요 · 월별 · 키워드(색인기준) · **AI 순수성** · 검색
- systemd 영구 실행 + Cloudflare 공개 터널

 <https://now-metallic-bringing-title.trycloudflare.com>

AWS 데이터허브 아키텍처 (W07 매핑)



현재 구현 상태: EC2 running · S3 버킷 생성 · Access Key 발급 · SSH/8501 개방

11. 결론 & 향후 계획

결론

- 전처리 고도화로 산업 기타 88.5% → 0%, 33,860건 정제 데이터 구축
- 공공 IT = 유지보수·운영 중심 / AI는 담론 대비 발주 격차 큼

향후 계획

- 첨부 PDF/HWP 본문 전수 추출 + LDA 토픽모델링
- 업무구분 '물품' 확장 · H3 가설 t-test 검증
- 뉴스 산업축 정합 (수요기관 기반과 통일)

감사합니다

GitHub github.com/hwangdongwuk/DataMining

대시보드 [trycloudflare](#) 공개 URL

데이터 33,860건 · 산업 10범주 · 사업유형 16범주

황동욱 · 데이터마이닝 2026