

공공 RFP × 산업 Pain Point 데이터 허브

나라장터 IT 발주 분석 · 2023-2025

데이터마이닝 중간과제 · **황동욱**

성균관대학교 정보통신대학원 · 2026 Spring

 33,860건 ·  수요기관 3,383곳 ·  35개월 ·  AWS 배포


1. 연구 질문 & 배경

- **연구 질문:** 공공부문은 어느 산업이, 어떤 유형의 IT 사업을, AI는 얼마나 발주하는가?
- **데이터 소스 (4종 결합):** 나라장터 OpenAPI · 네이버 뉴스 · FSC RSS · 첨부 RFP

“중간 검토의견서 4차 (P0): "산업 분류 '기타' 88.5% — 분류 자체가 작동하지 않음”

- 본 발표 = 이 피드백을 전처리 고도화로 해결한 과정과 결과

2. 데이터 파이프라인



단계	스택
수집	나라장터 OpenAPI · 월별 분할 · 지수 백오프
저장	AWS S3 (datamining-...-raw)
전처리	Python · 키워드 색인 · 기관 매핑 · 중복 제거
시각화·배포	Streamlit · EC2 systemd · Cloudflare 공개 터널

3. 전처리 고도화 — 정제 퍼널

전체 용역 공고

458,421

① IT 색인 (개발 다의어 제외)

53,909

② 영문토큰 단어경계

53,229

③ IT 비연관 도메인 제외

52,992

④ 논리적 중복 제거

33,860

+ ⑤ 산업 = 수요기관 기반 10범주 → 기타 0건 | ⑥ 사업유형 16범주 → 기타 7.5%

4. 핵심 버그 — 영문 토큰 부분일치

AI · SW 키워드가 **영어 단어 내부**에 박혀 오색인:

m
AI
ntenance

F
AI
r

MRI Br
AI
n

LG
AI
mers

pa
SSW
ord

- 산업 '기타' 258건 중 **102건이 이 오탐** (MRI 판독·해커톤·박람회...)
- **해결**: 영문 토큰 → 단어경계(\b) 매칭 / 한글 키워드 → 부분일치 유지

“데이터 양은 많은데 결론이 약해지는” 오염을 근본 차단

5. 데이터 규모

33,860

정제 공고

3,383

수요기관


35

개월 연속


10·16

산업·유형 범주

월별 공고 건수 추이



6. 산업별 분포 — 수요기관 기반 10범주



'기타' 0건 — 울산과학기술원 → 교육·연구, 한국거래소 → 금융 식 기관 기반 논리 배정

7.IT 사업유형 — 16범주

유형	비중	유형	비중
유지보수/운영	37.6%	감리	4.5%
구축/개발	17.7%	ISP/계획	1.8%
고도화/개선	11.9%	연구개발	1.8%
컨설팅/분석	5.8%	임차/구독	1.4%
보안	5.5%	기타	7.5%

“ 공공 IT 지출의 절반 이상이 유지보수·운영·고도화 — 신규 구축은 18%에 불과 ”

8. AI 순수성 — 담론 ↔ 발주 격차

 뉴스 (미디어 담론) — ai-pure

66.1%

 RFP (실제 공공 발주) — ai-pure

21.7%

💡 미디어는 **AI 중심**이지만 실제 공공 조달은 **일반 정보화·SI가 대다수** —
"AI 관심 ↔ 조달 현실"의 정량적 격차 (분류: ETRI KAIB2026)

9. 수요기관 Top (공고 건수)



정보화 전담기관(지능정보사회진흥원·인터넷진흥원)과 광역지자체가 공공 IT 발주를 주도

10. AWS 인프라 & 대시보드



- Streamlit 5탭: 개요 · 월별 · 키워드(색인기준) · **AI 순수성** · 검색
- 영구 실행(systemd) + 공개 터널 → 모바일 접속 가능

🌐 <https://now-metallic-bringing-title.trycloudflare.com>

11. 결론 & 향후 계획

결론

- 전처리 고도화로 산업 '기타' **88.5% → 0%**, 33,860건 정제 데이터 구축
- 공공 IT = **유지보수·운영 중심**, AI는 담론 대비 발주 격차 큼

향후 계획

- 첨부 PDF/HWP 본문 전수 추출 + LDA 토픽모델링
- 업무구분 '물품' 확장 · H3 가설 t-test 검증
- 뉴스 산업축을 수요기관 기반과 정합

감사합니다

GitHub github.com/hwangdongwuk/DataMining

대시보드 [trycloudflare](#) 공개 URL

데이터 33,860건 · 산업 10범주 · 사업유형 16범주

황동욱 · 데이터마이닝 2026