

발표 스크립트 — 공공 RFP × 산업 Pain Point 데이터 허브

데이터마이닝 기말 발표 · 황동욱 (2024720459) · 19장 · 예상 8~10분

1. 표지 (20초)

안녕하세요, 정보통신대학원 황동욱입니다. 발표 주제는 **공공 RFP와 산업 Pain Point를 결합한 데이터 허브**로, 나라장터 IT 발주 2023년부터 2025년까지 약 **3만4천 건**을 분석했습니다. 모든 결과는 AWS에 라이브로 배포돼 있습니다.

2. 연구 질문 & 범위 (40초)

연구 질문은 세 가지입니다. ① 산업별 반복 Pain Point를 정량화할 수 있는가, ② 그것이 컨설팅 유형 수요로 연결되는가, ③ Win Strategy를 자동 추출할 수 있는가. 중간발표 때 교수님께 "**산업 기타가 88.5%, 분류가 작동하지 않는다**"는 P0 지적을 받았습니다. 그래서 기말은 ①·② **검증과 분류 신뢰성 확보**에 집중하고, ③은 실무 서비스 형태로 구현했습니다.

3. 중간 → 기말 무엇이 달라졌나 (40초)

중간은 '기타 88.5%', 가설 제시만, AI 단순 매칭 등 **현황 기술 중심**이었습니다. 기말은 전처리 고도화로 **기타 0%**, H1·H3 **가설검정**, AI 정의 **엄격 재교정**, 제안서 자동생성 **서비스 구상**까지 진행했습니다. 한마디로 "**중간은 결과를 제시했고, 기말은 그 결과가 맞는지·왜 그런지를 검증했다**"입니다.

4. 피드백에 어떻게 답했나 (40초)

받은 피드백을 표로 정리했습니다. 교수님 P0 '기타 88.5%'는 **0%로**, Q3 't-test 검증' 요청은 **$p < 10^{-20}$ 지지**로, 동료들의 '기타 많아 교차 안 됨'은 **카이제곱 유의**로, '우편향 왜곡'은 **평균·중앙 병기와 log1p**로 답했습니다. AI 과대분류는 자체 점 검해 **21.7%→9.0%로 교정**했습니다. 첨부 PDF 전수추출과 규제 시차분석은 한계로 명시했습니다.

5. 데이터 파이프라인 (30초)

파이프라인은 수집-정제-검증-서비스-배포 5단계입니다. 나라장터 OpenAPI로 수집해 S3에 저장하고, Python으로 전처리, scipy로 검정, Streamlit과 Claude API로 서비스화했습니다. 이 중 **정제 단계가 핵심 기여**입니다.

6. 전처리 고도화 — 정제 퍼널 (50초)

전체 용역공고 45만 건에서 시작합니다. ① IT 색인으로 5.4만, ② 영문토큰 단어경계, ③ IT 비연관 도메인 제외, ④ 논리적 중복 제거를 거쳐 최종 **3만3,860건**으로 정제했습니다. 핵심은 산업 분류축을 '공고명 키워드'에서 '**수요기관 성격**'으로 바꾼 것인데, 이걸로 '기타'를 구조적으로 0건으로 만들었습니다.

7. 핵심 버그 — 영문 토큰 부분일치 (50초)

가장 중요한 버그입니다. AI, SW 같은 키워드가 영어 단어 내부에 박혀 오색인됐습니다. mAIntenance, FAIr, MRI brAIIn, paSSWord처럼요. 산업 '기타' 258건 중 **102건이 이 오탐**이었습니다. 영문 토큰은 단어경계(\b) 매칭으로, 한글은 부분일치를 유지해 "데이터는 많은데 결론이 약해지는" 오염을 근본 차단했습니다.

8. 데이터 규모 (30초)

정제된 공고 3만3,860건, 수요기관 3,383곳, 35개월 연속, 산업 10·유형 16범주입니다. 월별 추이는 회계연도 말에 발주가 몰리는 패턴을 보입니다. 추정가격은 평균 5.85억·중앙 1.22억으로 **4.8배 우편향**이라, 회귀에서는 log1p를 적용했습니다.

9. 가설 검정 — describe를 넘어 (50초)

중간발표 가설을 실제 검정했습니다. **H1:** AI 발주 비중이 6.1→8.0→13.4%, 2년 만에 2.2배 증가로 지지. **H3:** '고도화' 공고 예산이 1.55억 대 1.18억, Welch t=9.51, $p<10^{-20}$. 그리고 산업과 컨설팅 유형의 **카이제곱 2,824, $p\approx 0$** 으로 독립 기각, 즉 연관됨을 확인했습니다.

10. Q① 어느 산업이 AI를 발주하나 (40초)

첫 번째 질문의 답입니다. **정보·통신 22.3%, 교육·연구 14.4%**가 AI 발주를 주도하고, 의외로 **금융은 3.0%, 행정은 6.9%**로 담론 대비 발주가 저조합니다. 사업유형으로 보면 연구개발·POC/실증 비중이 높아 아직 실험 단계임을 시사합니다.

11. Q② 산업 × 컨설팅 유형 연결 (40초)

두 번째 질문입니다. 행정·공공은 **유지보수가 6,360건으로 압도적**이고, 교육·연구는 상대적으로 **구축 비중이 높습니다**. 카이제곱 2,824, $p\approx 0$ 으로 산업과 유형은 통계적으로 유의하게 연관됩니다. 동료들의 '기타가 많아 교차가 안 된다'는 지적을 **기타 0% + 검정**으로 해소한 슬라이드입니다.

12. AI 순수성 — 정의를 교정하다 (50초)

자체 검증입니다. 기존엔 '데이터·클라우드'만으로 AI로 판정해 **58.6%가 비AI 혼입**이었습니다. 엄격 정의로 다시 보면 뉴스 담론은 29.8%, 실제 RFP 발주는 9.0%입니다. 중요한 건 격차가 느슨한 정의(3.0배)나 엄격한 정의(3.3배)나 **유지된다**는 점 — 즉 정의를 바꿔도 'AI 담론과 조달 현실의 격차'라는 결론은 강건합니다.

13. IT 사업유형 — 16범주 (30초)

사업유형 16범주를 보면 유지보수·운영이 37.6%, 고도화 11.9%로 **절반 이상이 운영·유지보수**입니다. 신규 구축은 18%에 불과합니다. 공공 IT 지출이 신규보다 유지에 쏠려 있음을 보여줍니다.

14. AI 예산의 역설 (30초)

AI의 역설입니다. ai-pure 광고의 중앙 예산은 9천만 원으로, non-ai의 1.27억보다 **오히려 작습니다**(Welch $t=-6.91$, $p<10^{-11}$). AI는 비중도 작고 건당 예산도 작은, **아직 소규모 PoC·실증 단계**라는 뜻입니다.

15. 실무 서비스 구상 — 제안서 자동생성 (50초)

세 번째 질문을 서비스로 확장했습니다. 신규 광고가 들어오면 분류 엔진이 산업·유형·AI·키워드를 태깅하고, 회사 인적자산 기반으로 담당자를 매칭한 뒤, **Claude가 목차·핵심 메시지·차별화 전략이 담긴 가안 제안서**를 생성합니다. 제안서 1건 작성을 수일에서 수분으로 단축하는 게 목표입니다. 다만 담당자 매칭은 회사 DB 기반이라 본 발표는 대략적 구성·샘플 수준입니다.

16. AWS 인프라 & 대시보드 (30초)

인프라는 로컬 수집 → S3 → EC2 Streamlit(systemd 영구실행) → Cloudflare 공개 URL입니다. 대시보드는 개요·월별·키워드·AI순수성·검색·제안서생성 탭으로 구성돼 모바일에서도 접속 가능합니다. (시연 가능 시: 지금 바로 보여드리겠습니다.)

17. 결론 · 한계 · 향후 (40초)

결론입니다. 전처리 고도화로 기타 88.5%→0%, H1·H3 가설검정 지지, 산업×유형 연관 확인. AI는 답론 30% 대 발주 9%로 3.3배 격차이며 건당 예산도 작습니다. 한계는 솔직히 말씀드리면 산업축이 수요기관 기반이라는 점, 첨부 PDF 173건 샘플, FSC 30건 표본 부족입니다. 향후엔 PDF 전수추출과 LDA, 규제→발주 Granger 분석, 제안서 평가셋 구축을 계획합니다.

18. 예상 질문 Q&A (방어용)

- 기타 0%는 분류를 잘한 건가, 축을 바꾼 건가? → 후자입니다. 공고명 키워드는 한계가 있어 수요기관 성격으로 재정의했고, 한계도 명시했습니다.
- AI 9%는 너무 낮지 않나? → 엄격 정의 기준입니다. 느슨하면 21.7%이지만 답론 격차는 두 정의 모두 3배대로 강건합니다.
- 예산 t-test가 인과인가? → 아닙니다. 연관(association)이며, 기관·연도 통제 회귀는 향후 과제입니다.

19. 감사합니다 (10초)

이상입니다. GitHub와 라이브 대시보드 링크 남겨두었습니다. 핵심은 기타 0%, H1·H3 검정, AI 격차 3.3배, 제안서 자동생성입니다. 감사합니다.

발표 운영 팁

- 총 8~10분. 6·7·9·12번에 시간 배분(핵심 기여·검증).
- 5·8·13·14는 빠르게 넘기고 수치만 강조.
- 16번에서 라이브 시연 시 +1~2분 (가산점).
- Q&A 대비는 18번 3문항을 암기.