

발표 스크립트 — 공공 RFP × 산업 Pain Point 데이터 허브

데이터마이닝 기말 발표 · 황동욱 (2024720459) · 20장 · 예상 9~11분 (쉬운 설명 버전 — 통계용어 최소화)

1. 표지 (20초)

안녕하세요, 정보통신대학원 황동욱입니다. 주제는 **공공 RFP와 산업 Pain Point를 결합한 데이터 허브**입니다. 나라장터 IT 발주 2023~2025년 약 **3만4천 건**을 분석했고, 결과는 AWS에 라이브로 띄워 두었습니다.

2. 연구 질문 & 범위 (40초)

질문은 셋입니다. ① 산업별 반복 Pain Point를 숫자로 잡을 수 있나, ② 그게 컨설팅 수요로 이어지나, ③ Win Strategy를 자동 뽑을 수 있나. 중간발표 때 **"산업 기타가 88.5%, 분류가 작동 안 한다"**는 PO 지적을 받았습니다. 그래서 기말은 ①②를 제대로 검증하고, ③은 실무 서비스로 구현했습니다.

3. 중간 → 기말 (40초)

중간은 '기타 88.5%', 가설 제시만, AI 단순 매칭 등 **현황 나열**이었습니다. 기말은 전처리를 고도화해 **기타 0%**, 가설을 **실제로 검증**, AI 정의를 **엄격히 교정**했습니다. 한마디로 **"중간은 결과를 보여줬고, 기말은 그게 맞는지 검증했다"**입니다.

4. 피드백 응답 (40초)

받은 지적을 표로 정리했습니다. 교수님 '기타 88.5%'는 **0%**, 't-test 검증' 요청은 **검정으로**, 동료들의 '교차 안 됨'은 **교차분석으로**, 'AI 과대분류'는 **자체 점검해 9%로 교정**했습니다. 못 푼 한계(첨부 PDF 전수추출 등)도 솔직히 적었습니다.

5. 데이터 파이프라인 (30초)

수집-정제-검증-서비스-배포 5단계입니다. 나라장터 API로 모아 S3에 저장, Python으로 전처리, 통계 검증, Streamlit·Claude로 서비스화. 이 중 **정제가 핵심 기여**입니다.

6. 전처리 고도화 — 정제 퍼널 (50초)

전체 45만 건에서 IT 색인·단어경계·도메인 제외·중복 제거를 거쳐 **3만3,860건**으로 줄였습니다. 핵심은 산업 분류 기준을 '공고 제목 단어'에서 **'발주 기관의 성격'**으로 바꾼 것 — 이걸로 '기타'를 구조적으로 없앴습니다.

7. 핵심 버그 — 영문 토큰 부분일치 (50초)

가장 중요한 버그입니다. AI라는 글자가 mAIntenance, brAIn 같은 영어 단어 **속에** 박혀 엉뚱하게 AI로 잡혔습니다. '기타' 258건 중 **102건이 이 오류였어요**. 영어는 단어 단위로, 한글은 부분일치로 나눠 잡아 해결했습니다.

7. 데이터 규모 — 산업별 매트릭스 (40초)

규모만 보면 33,860건·3,383기관·35개월입니다. 그런데 산업별로 쪼개면 성격이 확연히 다릅니다. **건수는 행정·공공이 41.5%로 압도하지만, 건강 예산은 금융·보험이 3억대로 최고, AI 비중은 정보·통신이 22%로 최고입니다.** 즉 *"어디가 많이 발주하나"*와 *"어디가 비싸고 AI다운 사업을 하나"*는 다릅니다. — 뒤 슬라이드의 산업별 분석을 이 표로 미리 요약하는 장입니다.

8. 가설 검정 (50초) ★쉽게

세 가지를 확인했습니다. ❶ AI 발주가 해마다 느냐? → **네, 2년 새 2배.** ❷ '고도화' 사업이 예산이 더 큰가? → **네, 1.3배.** ❸ 산업마다 원하는 사업이 다른가? → **네, 뚜렷이 다름.** 셋 다 *"우연으로 보기 어렵다"* 수준으로 확인됐습니다(t-검정·교차분석 사용).

9. 어느 산업이 IT를 발주하나 (35초)

먼저 발주 '양'입니다. **행정·공공 41.5%, 교육·연구 18.7%** — 이 둘이 공공 IT 발주의 60%를 차지합니다. 즉 발주량은 공공·교육이 주도합니다.

10. 그중 AI는? (40초)

그런데 'AI 사업'만 보면 순위가 바뀝니다. **정보·통신 22.3%, 교육·연구 14.4%**가 주도하고, 발주량 1위였던 **행정·공공은 AI 비중 6.9%로 하위**입니다. 즉 *"많이 발주한다고 AI를 많이 하는 건 아니다"* — 양과 AI 성숙도는 별개입니다.

11. 산업 × 사업유형 연결 (40초)

산업마다 원하는 사업이 다릅니다. 행정·공공은 **유지보수가 압도적**(6,360건), 교육·연구는 **신규 구축 비중이 높습니다.** 교차분석으로 이 차이가 우연이 아님을 확인했습니다. 핵심은 *"산업을 알면 어떤 사업을 원하는지 예측할 수 있다"* — 제안 전략의 근거가 됩니다.

12. AI 순수성 — 정의 교정 (60초) ★수제버거 비유

식당 '수제' 간판 비유로 설명드리겠습니다. 간판에 '수제'라 쓴 집을 다 세면 수제집이 많아 보이지만, 진짜 손으로 만드는 집만 세면 적조. AI도 같습니다. '데이터·클라우드' 단어만 있어도 AI로 세면 뺑뺑이 — 실제로 그렇게 세니 **58.6%가 진짜 AI**였습니다. 진짜 AI만 세니, **뉴스에선 30%인데 실제 공고에선 9%.** *"말은 많은데 실제 사업은 적다"*는 거죠. 그리고 기준을 느슨하게 잡든 빡세게 잡든 **항상 3배 차이** — 그래서 믿을 만한 결론입니다.

13. IT 사업유형 16범주 순위 (35초)

16개 유형 전체 순위입니다. 상위 3개(유지보수·구축·고도화가 67%)에 집중돼 있고, 신규 구축은 18%뿐입니다. ISP·R&D·AI 같은 신규 기획성 사업은 각각 2% 미만 — 공공 IT가 '새로 만들기'보다 '운영·유지'에 쏠려 있음을 보여줍니다.

14. AI 예산의 역설 (35초) ★쉽게

AI의 역설입니다. AI 사업 1건 예산은 9천만 원으로, 비-AI 1건(1.27억)보다 **오히려 작습니다**(약 1.4배 차이, 우연 아님). *"IT/래 기술이라는데 정작 돈은 더 적게 쓴다"* — 아직 소규모 실험(PoC) 단계라는 뜻입니다.

15. 실무 서비스 — 제안서 자동생성 (50초)

세 번째 질문을 서비스로 확장했습니다. 신규 공고가 들어오면 분류 엔진이 산업·유형·AI를 태깅하고, 회사 인적자산으로 담당자를 매칭한 뒤, **Claude가 가안 제안서 초안**을 만듭니다. 제안서 1건을 수일에서 수분으로 줄이는 게 목표입니다. (담당자 매칭은 회사 DB 기반이라 본 발표는 샘플 수준입니다.)

16. AWS 인프라 & 대시보드 (30초)

로컬 수집 → S3 → EC2 Streamlit → Cloudflare 공개 URL 구조이고, systemd로 항상 떠 있어 모바일에서도 접속됩니다. (시연 가능 시: 지금 바로 보여드리겠습니다.)

17. 결론·한계·향후 (40초)

결론: 전처리로 기타 88.5%→0%, 가설 검증, 산업×유형 연관 확인. AI는 말 30% 대 실제 9%로 3배 격차이고 예산도 작습니다. 한계는 솔직히 — 산업축이 기관 기반이라는 점, 표본 부족. 향후엔 PDF 전수추출·LDA·제안서 정확도 평가를 계획합니다.

18. 예상 질문 Q&A (방어)

- 기타 0%는 분류를 잘한 건가, 축을 바꾼 건가? → 후자. 기관 성격으로 재정의, 한계도 명시.
- AI 9%는 너무 낮지 않나? → 엄격 기준입니다. 느슨하면 21.7%지만 격차는 두 기준 모두 3배대.
- 예산 차이가 인과인가? → 아니요, 연관입니다. 통제 회귀는 향후 과제.

19. (예비/여백)

시간 여유 시 12번 수제버거 비유나 16번 라이브 시연으로 보강.

20. 감사합니다 (10초)

이상입니다. GitHub·대시보드 링크 남겼습니다. 핵심은 기타 0%, 가설 검증, AI 격차 3배, 제안서 자동생성입니다. 감사합니다.

- 총 9~11분. ★표시(8·12·14)는 쉬운 설명 버전으로 천천히.
- 12번(AI 순수성)은 **수제버거 비유로 시작** → 청중 즉시 이해.
- 9·10번은 "발주량 1위 ≠ AI 1위" 대비를 강조.
- 13·14는 수치만 빠르게, 16번 시연 시 +1~2분.
- Q&A는 18번 3문항 암기.